

Tema 6

El intercambio Sesgo-Varianza (The Bias-Variance Tradeoff)

El intercambio Sesgo-Varianza

Al utilizar un modelo predictivo, el **error global** cometido por éste se debe a tres factores que se suman, suponiendo que y se relaciona con x mediante una función $y=f(x)$ desconocida y que estimamos por $\hat{f}(x)$:

We may estimate a model $\hat{f}(X)$ of $f(X)$ using linear regressions or another modeling technique. In this case, the expected squared prediction error at a point x is:

$$Err(x) = E[(Y - \hat{f}(x))^2]$$

This error may then be decomposed into bias and variance components:


$$Err(x) = \left(E[\hat{f}(x)] - f(x)\right)^2 + E\left[\hat{f}(x) - E[\hat{f}(x)]\right]^2 + \sigma_e^2$$

$$Err(x) = \text{Bias}^2 + \text{Variance} + \text{Irreducible Error}$$

El sesgo², que es el error promedio cometido por desfase de los verdaderos valores.

La varianza, que es la variabilidad de la forma del modelo y como consecuencia de sus predicciones al variar los datos utilizados para construirlo.

El error “irreducible” o no explicable por nuestro modelo. Este error es inherente a los datos y no depende del modelo que elijamos, por lo que siempre estará presente en nuestras predicciones.



Puntos azules: datos con los que se construye el modelo

Puntos naranjas: puntos externos de la misma

Modelo $M=0$: alto sesgo, varianza nula

Modelo $M=1$: mediano sesgo, relativamente baja varianza

Modelo $M=3$: bajo sesgo, relativamente baja varianza

Modelo $M=9$: relativamente bajo sesgo, muy alta varianza

$$y = \mu + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \beta_4 x^4 + \beta_5 x^5 + \beta_6 x^6 + \beta_7 x^7 + \beta_8 x^8 + \beta_9 x^9$$

$$y = \mu$$

$$y = \mu + \beta x$$

$$y = \mu + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

- Modelos con muchas variables, con muchas interacciones, o en general más complejos (más nodos en redes por ejemplo), tendrán **alta varianza** pero podrán tener **bajo sesgo** si esas variables e interacciones son predictivas y significativas.
- Modelos con pocas variables o poca complejidad tendrán **baja varianza** pero pueden tener **alto sesgo**.


En un modelo dado,

- Si queremos bajar el sesgo: introducimos más variables/ más complejidad.
- Si queremos bajar la varianza: quitamos variables/ reducimos complejidad.

1) Obviamente **queremos modelos con bajo sesgo y baja varianza. Pero al bajar el sesgo suele aumentar la varianza y viceversa.**


2) Cuando probamos nuestro modelo (por ejemplo con train-test) y medimos su error **una sola vez** sobre datos test para compararlo con otro modelo, **no podemos saber** qué parte del error que cometemos se debe **al sesgo o a la varianza**. Puede servir para estimar el sesgo en la predicción, pero no proporciona información directa sobre la varianza.

3) Para comparar modelos en términos de sesgo y varianza, valoraremos gráficamente la varianza a través de la **variabilidad del error observado bajo validación cruzada repetida**.




Modelos más **complejos** (más nodos en la red) tendrán **bajo sesgo** pero **alta varianza**.

Modelos más **simples** tendrán **alto sesgo** pero **baja varianza**



Algunos comentarios generales

1) La estimación de la varianza de un modelo no es fácil; construido el boxplot bajo CV repetida, recurriremos a la altura de la caja (rango intercuartílico Q3-Q1) y a la distancia entre sus bigotes como una **aproximación a la variabilidad** del modelo con vistas a comparación entre modelos (por eso se ha escrito “Varianza” entre comillas en el boxplot anterior).




2) Como se ha comentado respecto a los criterios de protección contra el sobreajuste, la observación empírica de sesgo y varianza se ampliará con el conocimiento concreto de las características de cada modelo, para que la comparación sea rica y consciente y las decisiones sobre preferencias entre modelos sean adecuadas:

- Número de variables
- Complejidad (número de nodos en la red por ejemplo)
- Valores numéricos concretos en el boxplot (eje y)
- Preferencia de modelos clásicos frente a modernos ante performance similares
- Etc.


3) Un método empírico que no tenga en cuenta la varianza del modelo puede estar expuesto a sobreajustes. Por ejemplo,

- Supongamos una red con un número de nodos exageradamente grande.
- Como la complejidad es grande, el sesgo baja y la varianza aumenta.
- Si la comprobamos esa red bajo CV **una sola vez**, nos dará un valor concreto del error. En una ejecución concreta unitaria, el error de predicción puede ser bajo porque el sesgo es bajo.
- Sin embargo estaríamos aceptando un mal modelo porque al ser su varianza alta, eventualmente el error podría alcanzar valores enormes. Pero al haberlo ejecutado una sola vez no lo sabemos.



4) Una manera de explicar el sobreajuste es que en un modelo sobreajustado nuestro modelo pretende reducir el error por debajo del error irreducible σ_e^2

- Como el error irreducible es desconocido no sabemos si estamos yendo más allá de lo razonable.
- Por ello necesitamos añadir a lo empírico razonamientos y consideraciones de concepto sobre nuestros modelos, el alcance de nuestras variables, el número de observaciones con el que se construye el modelo, etc.



5) En una aplicación real en Business Intelligence, Medicina, o cualquier ámbito, a menudo un gerente o responsable, si se le explica el concepto y consulta su opinión, priorizará la baja varianza aunque haya moderadamente alto sesgo.

Es frecuente que prefieran modelos robustos, estables, sacrificando precisión. Porque el riesgo de un patinazo ocasional es más grave que los beneficios obtenidos cuando se aspira a mayor precisión.

Otra razón es que la formación de muchos cuadros incluye los modelos clásicos (regresión lineal, regresión logística) y por tanto es más cómodo trabajar con ese tipo de modelos, que suelen tener baja varianza y técnicas descriptivas y de inferencia asociadas.

Esquema de trabajo en R

Se trabajará con funciones sencillas para construir datos de **error bajo CV repetida** en los diferentes modelos y **comparación gráfica de sesgo+varianza en boxplot**.

Archivo **ejemplos cruzada avnnet continua.R**

Función cruzadaavnnet (para red neuronal con avNNet)

- data frame y listados de variables

```
data=data, vardep="cstrength", listconti=c("age", "cement"),
```

- grupos de CV, semilla inicial, repeticiones de CV

```
grupos=4, inicio=1234, repe=15,
```

- parámetros de la red +nº de repeticiones de avnnet

```
size=c(10), decay=c(0.1), repeticiones=5, itera=500
```

```
medias1<-cruzadaavnnet(data=data,  
                        vardep="cstrength", listconti=c("age", "cement"),  
                        listclass=c(""), grupos=4, inicio=1234, repe=15,  
                        size=c(10), decay=c(0.1), repeticiones=5, itera=500)
```

Aquí se añade la columna con el nombre del modelo

```
medias1$modelo="avnnet"
```

Se obtiene:

	error	modelo
1	98.62502	avnnet
2	99.44391	avnnet
3	98.46193	avnnet
4	101.04676	avnnet
5	102.28074	avnnet
6	97.04975	avnnet
7	99.24544	avnnet
8	98.76589	avnnet
9	101.48693	avnnet
10	99.43073	avnnet
11	96.81563	avnnet
12	97.53448	avnnet
13	100.62752	avnnet
14	102.64581	avnnet
15	99.41600	avnnet

Cada observación contiene el error ASE (MSE) bajo CV en una repetición (en cada repetición se reordenan aleatoriamente los datos antes de realizar CV, según la semilla inicial *inicio*)

Función cruzadalin(para regresión lineal)

```
## Ejemplo de utilización cruzada regresión lineal


medias2<-cruzadalin(data=data,
                    vardep="cstrength",listconti=c("age","cement"),
                    listclass=c(""),grupos=4,sinicio=1234,repe=15)

medias2$modelo="lineal"
```

	error	modelo
1	187.6383	lineal
2	187.1027	lineal
3	187.4329	lineal
4	187.0823	lineal
5	186.9763	lineal
6	188.3593	lineal
7	187.7127	lineal
8	187.2830	lineal
9	186.6718	lineal
10	188.1124	lineal
11	187.4084	lineal
12	187.9661	lineal
13	188.1042	lineal
14	188.4678	lineal
15	186.8149	lineal

El objetivo de estas funciones es utilizar la comparación gráfica en **boxplot** para intuir sesgo y varianza de los modelos y establecer comparaciones.

```
## Unión de las medias y presentación del boxplot  
  
union1<-rbind(medias1,medias2)  
  
par(cex.axis=0.5)  
boxplot(data=union1,error~modelo)
```



Importante usar el modo “en paralelo” para cálculos más rápidos

```
library(parallel)

cluster <- makeCluster(detectCores() - 2) # number of cores, convention to leave 2 core for OS
registerDoParallel(cluster) # register the parallel processing
```

Se pueden comparar modelos con objetivos de resolver dudas en el tuneo, y tomar decisiones entre algoritmos (o con motivos pedagógicos como en este caso).

Como ejemplo de ilustrar cómo se comporta la red en términos de sesgo y varianza , aumentamos más allá de lo razonable el número de nodos y observamos el boxplot.

(5,10,15,20,30,60,80)

```
medias1<-cruzadaavnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(5),decay=c(0.1),repeticiones=5,itera=200)

medias1$modelo="05 nodos"

medias2<-cruzadaavnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(10),decay=c(0.1),repeticiones=5,itera=200)

medias2$modelo="10 nodos"

medias3<-cruzadaavnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(15),decay=c(0.1),repeticiones=5,itera=200)

medias3$modelo="15 nodos"

medias4<-cruzadaavnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(20),decay=c(0.1),repeticiones=5,itera=200)

medias4$modelo="20 nodos"

medias5<-cruzadaavnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(30),decay=c(0.1),repeticiones=5,itera=200)

medias5$modelo="30 nodos"
```

```
medias6<-cruzadaavnnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(60),decay=c(0.1),repeticiones=5,itera=200)

medias6$modelo="60 nodos"

medias7<-cruzadaavnnnet(data=data,
                        vardep="cstrength",listconti=c("age","cement"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=15,
                        size=c(80),decay=c(0.1),repeticiones=5,itera=200)

medias7$modelo="80 nodos"

union1<-rbind(medias1,medias2,medias3,medias4,medias5,medias6,medias7)
```

Nota gráfico boxplot:

Para reducir o ampliar la letra de los ejes: modificar cex.axis

Para poner la letra del eje x en vertical : poner las=2


```
par(cex.axis=0.5, las=2)
boxplot(data=union1, error~modelo)
```

Otros trucos para colores :

```
boxplot(data = union1, error ~ modelo, col = c("red"))

boxplot(data = union1, error ~ modelo,
        col = c("red", "blue", "green", "orange")) # Un color por caja
```

- Menos nodos: sesgo alto por complejidad insuficiente
- A medida que se aumentan los nodos se reduce el sesgo, pero se aumenta la varianza.
- Demasiados nodos: la varianza es excesivamente alta.
- Con la regla de calcular obs/parámetro nos quedaríamos con 10 nodos, modelo que tiene varianza pequeña con error promedio cercano a 100, y con 20 nodos, error cercano a 95 pero varianza más alta.
- El error irreducible parece estar en torno a 90.



Se puede reducir el sesgo mejorando características del modelo : añadir variables buenas, variar el algoritmo, buen tuneo, etc.

```
medias1<-cruzadaavnnet (data=data,
                        vardep="cstrength", listconti=c("age", "cement"),
                        listclass=c(""), grupos=4, inicio=1234, repe=15,
                        size=c(10), decay=c(0.1), repeticiones=5, itera=500)

medias1$modelo="avnnet1"

medias2<-cruzadaavnnet (data=data,
                        vardep="cstrength", listconti=c("age", "water", "cement"),
                        listclass=c(""), grupos=4, inicio=1234, repe=15,
                        size=c(10), decay=c(0.1), repeticiones=5, itera=500)

medias2$modelo="avnnet2"

medias3<-cruzadaavnnet (data=data,
                        vardep="cstrength", listconti=c("age", "water", "cement", "blast"),
                        listclass=c(""), grupos=4, inicio=1234, repe=15,
                        size=c(10), decay=c(0.1), repeticiones=5, itera=500)


medias3$modelo="avnnet3"

medias4<-cruzadalineal (data=data,
                        vardep="cstrength", listconti=c("age", "water", "cement", "blast"),
                        listclass=c(""), grupos=4, inicio=1234, repe=15)

medias4$modelo="lineal"

union1<-rbind(medias1,medias2,medias3,medias4)

par(cex.axis=0.5)
boxplot (data=union1,error~modelo)
```



Ejemplo Australian

En este ejemplo ilustramos como diferentes tuneos se reflejan en el intercambio sesgo varianza.

Australian es un problema con linealidad aparente.

- Aplicamos 20,25,30 y 500 iteraciones en el algoritmo de optimización en un modelo base (3 nodos, decay=0.25)
- Probamos un número demasiado alto de nodos para las obs. a ver qué pasa
- Comprobamos la regresión CON la interacción $ssf \times sex.f$, y sin ella.
- Como tenemos pocas observaciones me he permitido aumentar el número de repeticiones de CV a 25 porque da tiempo y cuantas más repeticiones más fiable la comparación.

```


medias1<-cruzadaavnnet(data=data,
                        vardep="lbm",listconti=c("hc","ssf","sex.f"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=25,
                        size=c(3),decay=c(0.25),repeticiones=5,itera=20)
medias1$modelo="20 iter"
medias2<-cruzadaavnnet(data=data,
                        vardep="lbm",listconti=c("hc","ssf","sex.f"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=25,
                        size=c(3),decay=c(0.25),repeticiones=5,itera=25)
medias2$modelo="25 iter"
medias3<-cruzadaavnnet(data=data,
                        vardep="lbm",listconti=c("hc","ssf","sex.f"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=25,
                        size=c(3),decay=c(0.25),repeticiones=5,itera=30)
medias3$modelo="30 iter"
medias4<-cruzadaavnnet(data=data,
                        vardep="lbm",listconti=c("hc","ssf","sex.f"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=25,
                        size=c(3),decay=c(0.25),repeticiones=5,itera=500)
medias4$modelo="500 iter"
medias5<-cruzadaavnnet(data=data,
                        vardep="lbm",listconti=c("hc","ssf","sex.f"),
                        listclass=c(""),grupos=4,sinicio=1234,repe=25,
                        size=c(6),decay=c(0.25),repeticiones=5,itera=30)
medias5$modelo="06 nodos"
medias6<-cruzadalin(data=data,
                     vardep="lbm",listconti=c("hc","ssf","sex.f","interaccion"),
                     listclass=c(""),grupos=4,sinicio=1234,repe=25)
medias6$modelo="1. con interacc"
medias7<-cruzadalin(data=data,
                     vardep="lbm",listconti=c("hc","ssf","sex.f"),
                     listclass=c(""),grupos=4,sinicio=1234,repe=25)
medias7$modelo="1. sin interacc"

```

```
union1<-rbind(medias1,medias2,medias3,medias4,medias5,medias6,medias7)

par(cex.axis=0.8, las=2)
boxplot(data=union1,error~modelo,col="pink")
```

- Con demasiados nodos (6) aumenta la varianza del modelo
- Aumentar las iteraciones del algoritmo lleva al sobreajuste (500)
- El modelo de regresión con la interacción es mejor que sin ella
- Preferiremos la regresión a la red con toda la info disponible : nube de puntos que muestra linealidad, valores empíricos en el boxplot con sesgo similar a la red y varianza naturalmente menor.



Para ser justos, probamos la red con la interacción también


```
# Usando en la red la interacción creada

medias8<-cruzadaavnnet(data=data,
                      vardep="lbm",listconti=c("hc","ssf","sex.f","interaccion"),
                      listclass=c(""),grupos=4,sinicio=1234, repe=25,
                      size=c(3),decay=c(0.25),repeticiones=5,itera=30)

medias8$modelo="Red-interac"

union1<-rbind(medias6,medias8)

par(cex.axis=0.8, las=2)
boxplot(data=union1,error~modelo,col="pink")
```



Revisión del error con el modelo final

- Para una estimación más fina del error, es bueno ampliar el número de grupos de CV. Hacemos una sola ejecución de CV con más grupos y valoramos el error medio y variabilidad.
- En este caso la varianza corresponderá a la variación del error respecto a una sola observación.
- Esta será mayor que la variación del error medio de la CV que se observa en los boxplots . Pues esta última es la varianza de la media del error tomada sobre muchas observaciones y la varianza de la media de varias observaciones es siempre menor que la varianza de una simple observación.

```
control<-trainControl(method = "cv",  
                      number=10,savePredictions = "all")  
set.seed(123)  
  
reg1<- train(lbm~hc+ssf+sex.f+ssf*sex.f,  
            data=australian2,  
            method="lm",trControl=control)  
  
reg1  
summary(reg1)  
  
resultados<-reg1$pred  
  
resultados$error<-(resultados$pred-resultados$obs)^2  
  
mean(resultados$error)  
sd(resultados$error)
```

```
# Para comprender mejor la performance predictiva de nuestro modelo, trabajamos con  
Absolute Error
```

```
hist(australian2$lbm)
```

```
mean(australian2$lbm)    # 64.87371
```

```
sd(australian2$lbm)      # 13.0702
```

```
resultados$errormae<-abs(resultados$pred-resultados$obs)
```


```
mean(resultados$errormae)    # 6.01
```

```
sd(resultados$errormae)      # 4.97
```


```
median(resultados$errormae)  # 5.17
```

```
hist(resultados$errormae)
```

Histogram of resultados\$errormae



- Asumiendo inferencia clásica un rango para el error al 95% se puede aproximar por $\text{media} \pm \text{sd} * 1.96$
- Esperamos aproximadamente un error de $6.01 \pm 1.96 * 4.97 = 6.01 \pm 10$ aproximadamente en una observación nueva con un 95% de confianza, es decir, entre -3.73 y 15.75 de error en la predicción de lbm (Lean Body Mass en kilogramos). Como mae no puede ser negativo, sería (0,15.75) aproximadamente en un 95% de los casos.
- El histograma da una idea aproximada más intuitiva de lo que puede pasar cuando predecimos lbm con nuestro modelo; no son errores normalmente distribuidos y la aproximación por el intervalo es algo inadecuada.



¿Es mucho? ¿Es poco?

Si yo predigo una observación por la predicción base (naif) que es la media, sin usar variables input, predigo 64.87 ; la media del error es 11.85, sd 7.32

```
resultados$errormedia<-abs(mean(australian2$lbm)-resultados$obs)
mean(resultados$errormedia)    # 11.85
sd(resultados$errormedia)      # 7.32

mean(resultados$errormae)      # 6.01

# Con las variables input utilizadas mi modelo tiene un error medio de 6.01 kg
aproximadamente, (+-10)
# Sin usar las variables input 11.85 kg  (+-1.96*7.32=14.3).


print(resultados[,c("errormae", "errormedia")])

# Es mucho mejor mostrar el histograma para hacerse una idea de lo que pasará
cuando predecimos lbm

hist(resultados$errormedia)
hist(resultados$errormae)
```


Con la predicción naif por la media

Histogram of resultados\$errormedia



Con la predicción con el modelo de regresión

Histogram of resultados\$errormae



```
# Igualmente añadimos el histograma con la mejor red

control<-trainControl(method = "cv",
                      number=10,savePredictions = "all")

set.seed(123)

nnetgrid <- expand.grid(size=c(3),decay=c(0.15),bag=F)

rednnet<- train(lbm~hc+ssf+sex.f,
               data=australian2,
               method="avNNet",linout = TRUE,maxit=25,
               trControl=control,repeats=5,tuneGrid=nnetgrid)

summary(rednnet)

resultados<-rednnet$pred

resultados$errormae<-abs(resultados$pred-resultados$obs)


mean(resultados$errormae)
sd(resultados$errormae)

# Coincide con la teoría, la red tiene menor sesgo pero mayor varianza que la regresión
para
# estos datos lineales

hist(resultados$errormae)
```


Con la predicción con la Red

Histogram of resultados\$errormae



Con la predicción con la Regresión

Histogram of resultados\$errormae



Recapitulación

- Cuando se comparan modelos predictivos, hay que tener en cuenta ambos sesgo Y varianza.
- Si solo se tiene en cuenta el sesgo , por ejemplo en una única repetición de CV, y se aplica un criterio automático (el modelo con menor error por CV), se corre el riesgo de escoger modelos que sobreajustan.
- Hay que reflexionar sobre el error irreducible en nuestros datos y si estamos intentando ir más allá de ese error.
- Las soluciones para “reducir” ese error “irreducible” en unos datos fijos son escoger y manipular bien las variables del modelo, escoger el algoritmo más apropiado, tunear correctamente.
- Las soluciones gráficas y razonamientos de concepto sobre el funcionamiento de cada algoritmo/tuneo permiten comprender mejor el intercambio sesgo-varianza en un problema concreto.

Ejercicio 6.1

Con el data frame Baseball2.Rda

- 1) Estandarizar las dos variables no_hits, yr_major.
- 2) Hacer una comparación sesgo-varianza de varias redes y regresión usando cruzadaavnnnet y cruzadalin:
 - a) El modelo que parecía el mejor tuneo realizado en el ejercicio anterior de tuneo de baseball2
 - b) Añadir alguna caja sobre algunas opciones de tuneo que podrían ser válidas
 - c) Añadir alguna exageración (iteraciones escasas o excesivas, nodos exagerados)
 - d) Añadir una caja de regresión y conclusiones
 - e) Mostrar el histograma del error de predicción con la mejor red y con la regresión

Ejercicio 6.2

El data frame Seoul.Rda tiene las siguientes variables, donde Rented Bike count es la variable objetivo :

Date : year-month-day

Rented Bike count - Count of bikes rented at each hour

Hour - Hour of the day

Temperature-Temperature in Celsius

Humidity - %

Windspeed - m/s

Visibility - 10m

Dew point temperature - Celsius

Solar radiation - MJ/m²

Rainfall - mm

Snowfall - cm

Seasons - Winter, Spring, Summer, Autumn

Holiday - Holiday/No holiday

Functional Day - NoFunc(Non Functional Hours), Fun(Functional hours)

1) Usaremos solo como input "Hour", "Temperature..C.", "Humidity...", variable objetivo Rented Bike count.

Estandarizar las variables input. Presentar nube de puntos. Calcular obs/parámetros con diferentes número de nodos.

2) Estudiar gráficamente el tuneo de nodos, size, decay como en “ejemplo compress ciencia datos.R”)

3) Comparar gráficamente con cruzadavnnnet y cruzadalin:

a) El modelo que parecía el mejor tuneo realizado en el apartado 2

b) Añadir alguna caja sobre algunas opciones de tuneo que podrían ser válidas

c) Añadir alguna caja con exageración (iteraciones escasas o excesivas, nodos exagerados)

d) Añadir una caja de regresión y conclusiones

e) Mostrar el histograma del error de predicción con la mejor red y con la regresión